

دانشگاه شهید بهشتی

دانشکده مهندسی و علوم کامپیوتر

کاهش شروعهای سرد در پلتفرمهای بدون سرور

گزارش سمینار کارشناسی ارشد مهندسی کامپیوتر گرایش نرمافزار

> نگارش امیرمحمد کرمزاده

> > استاد راهنما

دكتر عليرضا شاملي

چکیده

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ و با استفاده از طراحان گرافیک است. چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است و برای شرایط فعلی تکنولوژی مورد نیاز و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می باشد. کتابهای زیادی در شصت و سه درصد گذشته، حال و آینده شناخت فراوان جامعه و متخصصان را می طلبد تا با نرم افزارها شناخت بیشتری را برای طراحان رایانه ای علی الخصوص طراحان خلاقی و فرهنگ پیشرو در زبان فارسی ایجاد کرد. در این صورت می توان امید داشت که تمام و دشواری موجود در ارائه راهکارها و شرایط سخت تایپ به پایان رسد وزمان مورد نیاز شامل حروفچینی دستاوردهای اصلی و جوابگوی سوالات پیوسته اهل دنیای موجود طراحی اساسا مورد استفاده قرار گیرد.

واژگان کلیدی: رایانش ابری، رایانش بدون سرور، شروعهای سرد، FaaS ،function-as-a-service

فهرست مطالب

1	4	مقدم	1
۲	صورت مسئله	١.١	
٢	انگیزهی تحقیق	۲.۱	
٣	مثال مرتبط	٣.١	
۴	اهمیت موضوع	۴.۱	
۵	نتیجههای مهم تحقیق	۵.۱	
۶	ی بر ادبیات	مروري	١
٧	رایانش بدون سرور	١.٢	
٧	۱.۱.۲ تعریف رایانش بدون سرور		
١.	۲.۱.۲ معماری		
١١	۳.۱.۲ ویژگیهای پلتفرمهای بدون سرور ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰ ۰		
14	۴.۱.۲ پلتفرمهای تجاری		
۱۵	۵.۱.۲ پلتفرمهای آزاد و متن باز		
18		۲.۲	
۱۷		٣.٢	
۱۸	تاخبر شروع سرد	4.7	

۲٠	ِهای مرتبط	کار	٣
74	۱ درخت موضوعی	۳. ۱	
78	۲ بهینه سازی محیط	۳.۲	
78	۱.۲.۳ کاهش زمان آمادهسازی کانتینرها		
٣۵	۳ کاهش رخدادهای شروع سرد	۳.۳	
٣۶	جهگیری	نتي	۴
٣٨		اجع	مرا

فهرست شكلها

۴	اهمیت شروع سرد	1.1
٩	مرزهای رایانش بدون سرور و رایانش سرورآ گاهانه	١.٢
١.	معماری کلی یک پلتفرم بدون سرور	۲.۲
۱۸	اهمیت زبان و پلتفرم بدون سرور در تاخیر شروع سرد	٣.٢
۱۹	اهمیت اندازه کتابخانه برنامه در تاخیر شروع سرد	۴.۲
77	الگوی بازتابی در فراخوانیها	۱.۳
۲۳	الگوی همجوشی در فراخوانیها	۲.۳
۲۳	الگوی همجوشی در فراخوانیها	٣.٣
	مقایسه زمان اجرا ۲ برنامه مشابه با Node.js و پایتون در دو پلتفرم ASF و IBM Cloud	۴.۳
۲۵		
۲۵	درخت موضوعی	۵.۳
۲۹	معماری پلتفرم Knative معماری پلتفرم	۶.۳
٣٠	معماری پیشنهادی مقاله برای حل تاخیر شروع سرد	٧.٣
٣١	مراحل ساخت یک فضای نام در داکر	۸.۳
٣٣	استفاده از Pause Containerها برای کاهش تاخیر شروع سرد	٩.٣
٣۴	مدير استخر Pause Containerها	۲٠.۳

٣۴	 ۱۱.۲ نتیاج و بهبود حاصل شده با استفاده از Pause Containerها	٢
	, , , , , , , , , , , , , , , , , , ,	

فهرست جداول

74		•		•	•	•	•	•	•	•	•	•	•		•	•	•	مقایسهی بین روشهای ترکیب توابع	١.٣
٣٣			•			•									(ان	زما	زمان ساخت و پاکسازی کانتیرهای همز	۲.۳

فصل ۱

مقدمه

مقدمه

۱.۱ صورت مسئله

چه روشهایی برای کاهش تعداد شروعهای سرد در پلتفرمهای بدون سرور ۱ با حداقل سربار ۲ و زمان اجرایی وجود دارند؟

۲.۱ انگیزهی تحقیق

رایانش بدون سرور ^۳ یکی از مسائل داغ و محبوب اینروزهای دنیای مهندسی نرمافزار و رایانش ابری است. رایانش بدون سرور حوزه ی جدیدی را در توسعه ی محصول و استقرار ^۴ اپلیکیشنها باز کرده است. یکی از دلایل محبوبیت استفاده از پلتفرمهای بدون سرور و تمایل توسعه دهندگان برای مهاجرت به سمت آن، استفاده بیش از پیش از معماری میکروسرویس و نانوسرویس در توسعه ی محصولات و حرکت معماران و مهندسین نرمافزار در تولید و مهاجرت برنامههای کاربردی با این معماری ها است.

از دید توسعه دهنده، رایانش ابری با حذف دخالت مستقیم کاربران انتهایی در مدیریت زیرساخت ازجمله 0 برنامه lrload-balancing یا prauto-scaling موجب بهبود سرعت توسعه محصول و تمرکز کاربران برروی منطق 0 برنامه است. همچنین، برای علاوه بر آسانی استفاده و پنهان سازی پیچیدگی مدیریت سرور از کاربر، به علت اینکه ارائه دهندگان خدمات ابری در نقاط مختلف جهان حضور دارند و همچنین کانفیگ بهینه CDNها؛ ارتباطات بین سرورها و کاربران با حداقل تاخیر 0 صورت می گیرد.

به طور کلی، یک پلتفرم بدون سرور را هر پلتفرم محاسباتی تعریف کرد که در آن مدیریت مستقیم سرور از کاربران مخفی شده و برنامههای کاربردی به صورت اتوماتیک در آن مقیاس پذیر می شوند و تنها هنگامی که در حال استفاده از پلتفرم هستیم، هزینه آن را پرداخت می کنیم. [۱]

یکی از قابلیتهایی که در رایانش بدون سرور باعث محبوبیت آن شده است، قابلیت Scale-to-Zero است. این بدان معنی است که هنگامی که از یک کانتینر استفاده ای نداریم، منابع آن گرفته می شوند و کانتینر اصطلاحا

¹serverless

²Overhead

³Serverless Computing

⁴Deployment

⁵logic

⁶Latency

مقدمه

Zero-Scaled می شود. این خود موجب قابلیت پرداخت تنها در حین مصرف ما از تابع می شود. اما مشکل اصلی زمانی است که درخواست جدیدی برای کانینر Zero-Scale شده می رسد؛ در این حالت باید درخواست منتظر مانده تا سلسله ای از آماده سازی ها انجام شوند تا کانتینر مربوطه مجددا اجرا شود. این خود باعث تاخیری مضاف برای پاسخدهی به درخواست را موجب می شود که به این تاخیر مشکل شروع سرد اگفته می شود. در واقع می توان گفت تاخیر شروع سرد ناشی از تلاش ما در تعادل بین تاخیر در پاسخگویی به درخواستها و هزینه (هزینه های استفاده از رم و سی پی یو و ...) است.

متاسفانه در سالیان اخیر و در عین داغبودن مبحث و نیاز بازار به حل این مشکل، این مشکل چندان در محیطهای آکادمیک مورد بررسی قرار نگرفته است. البته در نگاه کلی تر، مشکلات و مسائل بار مربوط به رایانش بدون سرور، اکثرا در محیطهای آکادمیکی مثل دانشگاهها با کم محلی روبرو شده اند. در این میان، پلتفرمهای متن باز ^۲ که دارای جوامع بسیار گسترده ای نیز هستند، به خاطر این سری مسائل باز که شرکتهای تجاری در حال صرف هزینههای هنگفتی برای حل و فصل مسکلات مربوط به آن هستند، به شدت از رقابت عقب مانده اند. انگیزه ما برای انجام این پژوهش در این است که اولا بتوانیم به راهکار مناسب تری برای حل مشکل مربوط به شروع سرد در پلتفرمهای بدون سرور برسیم و ثانیا بتوانیم با مشارکت در بهبود یکی از پلتفرمهای آزاد در توسعه این پلتفرمها تاثیر کوچکی داشته باشیم.

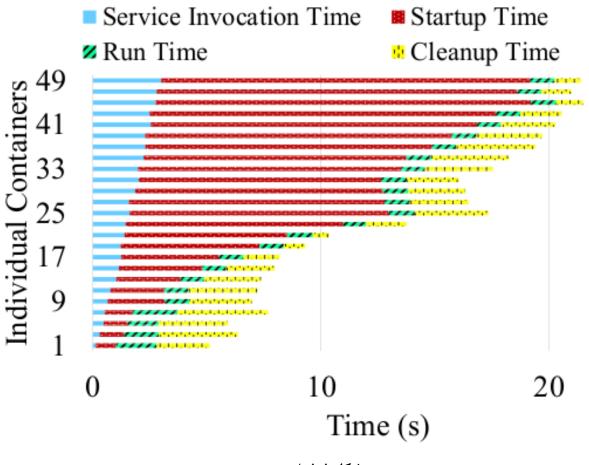
٣.١ مثال مرتبط

در مقاله [۲] آقای لین و همکارش توانستند تا با اسفاده از استخر گرم و نگهداری کانتینر توابعی که محبوبیت استفاده دارند، مدت زمان پاسخ را در حدود ۸۵٪ کاهش دهند. این بهبود در پلتفرم knative اجرا شد و ایده ی مقالات دیگری نیز بوده است.

¹Cold Start

²Open Source

مقدمه



شكل ۱.۱: اهميت شروعسرد

۴.۱ اهمیت موضوع

اگرچه پلتفرمهای بدون سرور از نظر هزینه، scaling، راحتی استفاده و گستردگی پوشش جغرافیایی برای ما بهینه هستند؛ اما مشکل شروع سرد مشکلی نیست که بتوان به سادگی از آن گذر کرد. تصویر ۱.۱ که از [۳] گرفته شده است، نشان می دهد که بیش از ٪۸۰ زمان اجرای کامل یک کانتینر در پلتفرمهای بدون سرور به آماده سازی آن یا شروع سرد اولیه ۱ مربوط می شود.

ستون قرمز رنگ زمان آماده سازی کانتینر را نمایش میدهد. این زمان همان زمان شروع سرد است که دلایل مختلفی از جمله آماده سازی کانتینر یا حضور در صف انتظار برای تخصیص منابع باشد. بنابراین، با به کارگیری یک استراتژی مناسب می توان این زمان را به حداقل رسانید.

متاسفانه تاخیر شروع سرد باعث شده تا توسعهدهندگان اقبال کمتری به استفاده از پلتفرمهای بدون سرور

¹First Cold Start

مقدمه مقدمه

داشته باشند. به گونهای که از بین ۱۰۰۰ برنامه کاربردی بزرگ در پلتفرم Microsoft Azure، تنها یک مورد مربوط به یک برنامه تجاری باشد [۴]. این موضوع نشان می دهد که علی رغم پتانسیل بالای رایانش بدون سرور، وجود مشکلات جدی از جمله شروع سرد، باعث امتناع توسعه دهندگان از مهاجرت به پلتفرمهای بدون سرور باشد.

۵.۱ نتیجههای مهم تحقیق

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ، و با استفاده از طراحان گرافیک است، چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است، و برای شرایط فعلی تکنولوژی مورد نیاز، و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می باشد، کتابهای زیادی در شصت و سه درصد گذشته حال و آینده، شناخت فراوان جامعه و متخصصان را می طلبد، تا با نرم افزارها شناخت بیشتری را برای طراحان رایانه ای علی الخصوص طراحان خلاقی، و فرهنگ پیشرو در زبان فارسی ایجاد کرد، در این صورت می توان امید داشت که تمام و دشواری موجود در ارائه راهکارها، و شرایط سخت تایپ به پایان رسد و زمان مورد نیاز شامل حروفچینی دستاوردهای اصلی، و جوابگوی سوالات پیوسته اهل دنیای موجود طراحی اساسا مورد استفاده قرار گیرد.

ساختار این گزارش به این ترتیب خواهد بود:

درادبیات موضوع مروری بر واژگان، مفاهیم تخصصی و هر آنچه که در ادامه به آن نیاز پیدا خواهیم کرد، خواهیم درادبیات موضوع مروری بر واژگان، مفاهیم تخصصی و هر آنچه که در ادامه به آن نیاز پیدا خواهیم پرداخت و در خواهیم داشت. سپس در فصل کارهای از مطالعات انجام شده و مسائل باز خواهیم پرداخت.

فصل ۲

مروری بر ادبیات

در این بخش سعی داریم تا با مروری بر اصطلاحات و ابزارهای مورد استفاده در پژوهشهای بررسی شده، با پیشنیازهای مبحث موردنظر آشنا شویم.

۱.۲ رایانش بدون سرور

رایانش بدون سرور ۱ در سال ۲۰۱۴ توسط شرکت آمازون برای اولین بار معرفی شد. تا قبل از این رایانش بدون سرور یک مفهوم انتزاعی ۲ در شبکه بود که شرکت آمازون با ارائه پلتفرم AWS Lambda Functions ابری نیز به ارائه پلتفرمهای بدون سرور خود معرفی آن پرداخت. سپس در سال ۲۰۱۶ سایر ارائه دهندگان خدمات ابری نیز به ارائه پلتفرمهای بدون سرور خود پرداختند. در این سال به ترتیب شرکتهای گوگل پلتفرم google cloud functions یا به اختصار GCP، شرکت مایکروسافت پلتفرم Microsoft Azure functions و شرکت IBM OpenWhisk پرداختند. البته باید توجه داشت که مفهوم رایانش بدون سرور به طور کامل توسط ارائه دهندگاه خدمات ابری پیادهسازی نشده است و جای کار بسیاری دارد (با مطالعه این گزارش به مرور متوجه نواقص موجود خواهید شد).

در رایانش بدون سرور ما از نقطه قوت ماشینهای مجازی که ایزولاسیون برنامههای مختلف از همدیگر بود استفاده کرده ایم. در ادامه راجع به کانتینرها نیز بحث خواهیم کرد.

۱.۱.۲ تعریف رایانش بدون سرور

رایانش بدون سرور مبحثی از رایانش ابری است که در آن بحث مدیریت حافظه یا Storage، مدیریت زیرساخت و بحثهای networking با انتزاع بالایی به مصرف کاربر میرسد. به عبارت دیگر، تمامی مدیریت ای بخشها بر عهده ارائه دهندگان است و ما اصلا با این بحث ها سروکاری نداریم. در واقع، هدف اصلی رایانش بدون سرور هم این است که این پیچیدگیها را از کاربر بگیرد.

به طور کلی، یک پلتفرم بدون سرور را هر پلتفرم محاسباتی تعریف کرد که در آن مدیریت مستقیم سرور از کاربران مخفی شده و برنامههای کاربردی به صورت اتوماتیک در آن مقیاس پذیر می شوند و تنها هنگامی که در

¹Serverless Computing

²abstract

حال استفاده از پلتفرم هستیم، هزینه آن را پرداخت می کنیم. [۱]

بسیاری از افراد، serverless و faas را معادل یک دیگر می دانند در حالی که اصلا این گونه نیست. در ادامه راجع به این بحث به طور مفصلی بحث خواهیم کرد اما باید بدانیم که این دو مقوله کاملا جدا از همدگیر هستند و مجددا تاکید می کنیم که رایانش بدون سرور یک مدل اجرایی در رایانش ابری است.

ازطرفی رایانش بدون سرور را باید نقطه مقابل رایانش سرور آگاهانه ۱ دانست که در آن از اطلاعات سرور در مسلامی انتخار گرفته کاملا اگاهیم، کاملا بر مدیریت آن اشراف داریم و هرگونه تغییر از جمله متعادل سازی بارها، -auto و scaling و ... باید توسط کاربر انجام شود.

یک مثال از پیاده سازی رایانش سرور آگاهانه را در زیرساخت به عنوان سرویس ^۲ یا به اختصار IaaS است. در نقطه مقابل در رایانش بدون سرور هیچ کنترلی بر روی سرور نداریم، تنها می توانیم یک برنامه را بر روی سرور اجرا کنیم یا اجرای آن را به حالت تعلیق درآورده یا آن را از روی سرور حذف کنیم که هیچ کدما از این موارد نیز به صورت مستقیم انجام نمی گیرد؛ بلکه رابط گرافیکی و API وجود دارد که از طریق آنها این تغییرات را اعمال می کنیم. بنابراین در رایانش بدون سرور، عملا هیچ راهی برای مدیریت مستقیم سرور و زیرساخت نداریم.

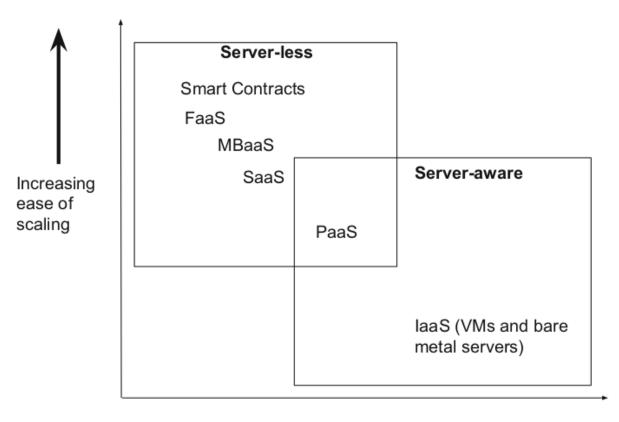
شکل ۱.۲ مرزهای بین رایانش بدون سرور و رایانش سرور آگاهانه را نمایش می دهد.

البته باید به این نکته توجهداشت که امروزه مرزهای بین رایانش سرور آگاهانه با رایانش بدون سرور در حال کمرنگ شدن و بعضا از بین رفتن است و این تقسیم بندی ابدا قاطعیت ندارد. همچنین تفکیک برخی موارد مانند Platform-as-a-Serice یا به اختصار PaaS به راحتی انجام نمی گیرد بلکه این نوع رایانش می تواند از نوع باسرور یا بدون سرور باشد. در این شکل هرچه به سمت محور افقی حرکت می کنیم دانه بندی و طول عمر افزایش پیدا می کند و هرچه به سمت بالاتر می رویم، scalingz راحت تر انجام می گیرد.

از مزایای رایانش بدون سرور همچنین می توان به پشتیبانی و توسعه راحت تر اپلیکیشن ها با معماری میکروسرویس و نانوسرویس هم اشاره کرد. البته معماری نانوسرویس مبحث جدید تری است و جای پژوهش های بیشتری دارد.

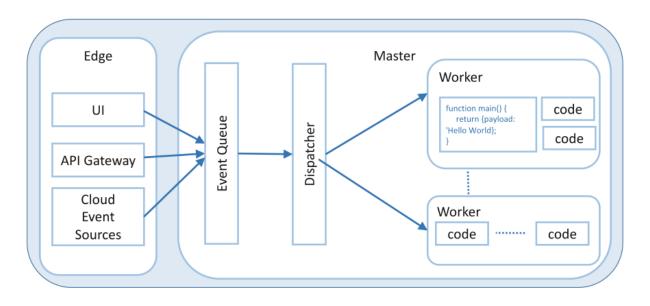
¹Server Aware

²Infrastructure as a service



Increasing size and lifetime -

شکل ۱.۲: مرزهای رایانش بدون سرور و رایانش سروراً گاهانه



شکل ۲.۲: معماری کلی یک پلتفرم بدون سرور

١

۲.۱.۲ معماری

واژه serverless ممکن است این تفکر را به ذهن مبتدر سازد که اصلا در این نوع مدل رایانشی سروری نداریم؛ در حالی که این امر بسیار اشتباه است. در رایانش بدون سرور اگرچه سروری برای مدیریت به کاربر اختصاص داده نمی شود اما این موضوع بدان معنا نیست که اصلا سروری در کار نیست. در واقع مانند تمامی مدل های رایانشی در این جا هم سرور داریم، ولی تمامی تصمیمات مثل توزیع بار، تعداد اپهای روی سرور، انتخاب سرورها برای اجرای این جا هم سرور داریم، ولی تمامی تصمیمات مثل توزیع بار، تعداد اپهای روی سرور، انتخاب سرورها برای اجرای این جا هم سرور داریم، ولی تمامی تصمیمات مثل توزیع بار، تعداد اپهای روی سرور، انتخاب سرورها برای اجرای سرور، بهتر است با معماری آن آشنا باشیم. شکل ۲.۲ معماری یک پلتفرم خدمات ابری را نشان می دهد.

همانگونه که در تصویر مشخص است دوبخش کلی داریم، بخش لبه 7 و بخش رییس 8 ، بخش لبه شامل رابط گرافیکی کاربر 4 ، Gateway API و Cloud Event Source می شود که برای تعامل با سرور رییس مناسب هستند. از طرف دیگر، در سرور رییس، در خواستها ابتدا به صف ر خدادها 8 رسیده. صف ر خدادها مسئول مدیریت ر خداد

²edge

³master

⁴User Interface

⁵master server

⁶Event Queue

و نظم دهی به آنّها است. هر داده در صف رخداد نوبت دهی می شود و سپس به بخش توزیع کننده امی رود. توزیع کنند آپلیکیشن را برای دیپلوی، یا در خواست را برای سرویس دهی به یک نود کارگر هدایت می کند نود کارگر نیز با ارسال کدهای پاسخ 7 با سرور رییس در ارتباط است. [۵]

البته بهتر است بدانیم که امروزه ادبیات رییس-کارگر * برای نامیدن این معماری منسوخ شده و به جای آن از ادبیات رییس-گره 0 استفاده می کنند.

۳.۱.۲ ویژگیهای پلتفرمهای بدون سرور

امروزه پلتفرمهای بدون سرور بسیاری وجود دارند که روزانه بر تعداد آنها افزوده می شود. اما باید دنبال ویژگیهایی برای آنها باشیم که براساس آنها بتوان این پلتفرمها را تفکیک کرد و دست به مقایسه ی آنها زد. شاخصهایی که در این قسمت بررسی می کنیم شاخصهای کمی و کیفی برای مقایسه ی بین این پلتفرمها است.

۱. هزینه:

به طور معمول در رایانش بدون سرور، از مدل پرداخت پرداخت-به-ازای-استفاده 8 استفاده می کنیم. یک ویژگی اساسی در تمایز بین ارائهدهندگان مختلف خدمات ابری، تفاوت آنها در پشتیبانی از ویژگی scale-to-zero در این مدل محاسباتی 9 است. این مورد باعث تفاوت معنی داری از هزینهها در استفاده از پلتفرمهای مختلف می شود. بر خی از پلتفرمها هم متن باز 6 هستند که در این صورت، می توان به آسانی آنها را بر روی ماشین مجازی یا سرور شخصی خود پیاده سازی کرد و برای استفاده از خدمات آن متحمل هیچگونه هزینهای نشد.

۲. کارایی و محدودیتها^۹

¹dispatcher

²worker node

³Response Code

⁴Master-worker

⁵Master-Node

⁶pay-as-you-go

⁷Computational Model

⁸Open Source

⁹Performance and Limits

ارائه دهندگان مختلف، محدودیتهای مختلفی را هم بر روی پلتفرمهای مختلف خودشان اعمال می کنند. این محدودیتها می توانند تعداد همزمان درخواست ها requests)، concurrent of (number حداکثر است. PAM و CPU د توسط یک تابع، حداکثر زمان زنده ماندن بعد از اجرا توسط تابع و ... است. البته برخی از محدودیتها را می توان با صرف هزینه یا خرید پلنهای درامدی سطح بالاتر برطرف کرد. مثلا پلتفرم functions Lambda AWS می تواند با صرف هزینهی بیشتری حداکثر تعداد درخواست را افزایش داد. در حالی که این مورد در پلتفرمهای اوپن سورس وجود ندارد. در حالت کلی پلتفرمهای متن بازی مثل محدودیتهای بیشتری را برای کاربر اعمال می کنند. علت این امر می تواند این باشد بازی مثل نظر تکنولوژی و بازدهی (performance) کاملا از همتایان تجاری خود عقب هستند.

۳. زبان برنامهنویسی ۱

پلتفرمهای بدون سرور از گستره ی عظیمی از زبانهای برنامهنویسی پشتیبانی می کنند که شامل جاوااسکریپت، گو، پایتون، جاوا، سی شارپ، سویفت و پی اچپی می شود. اکثر پلتفرمها حداقل از ۵ زبان برنامهنویسی پشتیبانی می کنند. همچنین بسیاری از پلتفرمها مستقل از زبان ۴ هستند. یعنی در حالی که در داخل کانتینر اجرا می شوند (مثلا کانتینرهای داکر)، دیگر زبان برنامهنویسی برای آنها اهمیتی ندارد. این پلتفرمها توابع را در داخل کانتینر اجرا می کنند و نتیجه را برمی گردانند.

۴. مدل برنامهنویسی ۳

مدلهای مختلفی برای تولید یک متد در پلتفرمهای بدون سرور داریم. شیوه متداول استفاده از یک متد به نام main است که درون آن تابع اصلی تعریف می شود. همچنین معمولا ورودی های تابع در قالب شیئهای json تعریف می شوند.

۵. ترکیب توابع^۴

روشهای گوناگونی برای اینکه یک تابع یا جریان کاری پیچیدهرا پیاده سازی کنیم وجود دارد. یک روش

¹Programming Languages

²Language Independent

³Programming Model

⁴Compositions

استفاده از ترکیبهای توابع است. تا به حال ۷ ترکیب مختلف شناسایی شده است. پلتفرمهای تجاری استفاده از ترکیبهای برای پیاده سازی این ترکیبات در خود تعبیه کرده آند. متاسفانه پلتفرمهای متن باز مثل ۲ از این ترکیب پشتیبانی نمی کنند. در ادامه و در بخش کارهای مرتبط این ویژگیها مطرح خواهند شد. کاربرد اصلی ترکیب توابع پیاده سازی عملکردهای پیچیده در پلتفرم بدون سرور است.

استقرار ۳

پلتفرمها سعی می کنند پیاده سازی ها در رایانش بدون سرور را تا حد ممکن ساده کنند. این یکی از دلایل به وجود آمدن این مدل رایانشی بوده. به صورت معمول پلتفرمها برنامهها را در قالب کانتینرهای داکری دریافت می کنند و درون کانتینر مربوطه کد را اجرا می کنند. علاوه بر داکر پلنهایی از جمله دریافت کد باینری، دریافت سورس کد و سپس کانینرایز کردن آن وجود دارد.

٧. امنیت و حسابدری ٔ

این دو مورد در کنارهمدیگر به کار برده می شوند که معمولاخارج از بحثهای رایانش ابری کاملا جدا از همدگیر به کار برده می شوند. در رایانش بدون سرور لازم است که اپها کاملا از همدگیر جدا اجرا شوند به این دلیل که بتوانیم برای هر کاربر هزینه ای که باید پرداخت کند را محاسبه کنیم. درصورتی که اجرای کاربران از همدگیر تفکیک شده نباشد، محاسبه ی هزینه ممکن نیست. اما اجرای جداگانه ی توابع از یکدیگر علت دیگری نیز دارد، امنیت. لازم است که توابع جداگانه اجرا شوند تا در توابع و کاربران نتوانند در کارهای همدیگر دخالتی داشته باشند. این مورد حتی می تواند باعث به وجود آمد باگهای امینتی و دسترسی کاربران به سیستم کاربران دیگر از طریق مدل رایانشی ما شود.

$^{\Delta}$. پایش و اشکال زدایی $^{\Delta}$

هر پلتفرم رایانشی امکاناتی از جمله پایش اولیه برای در خواستها را به کاربر می دهد. البته این بحث یکی از مسائل باز در این حوزه است و نیاز به بررسی بیشتری دارد. در حال حاضر دیباگینگ از طریق تجزیه

¹orchestrator

²openfaas

³Deployments

⁴Security and Accounting

⁵Monitoring and Debugging

و تحلیل لاگهای سیستم ممکن است ولی ممکن است در آینده بهبودهایی در این حوزه حاصل شود. علت اینکه دیباگینگ بسیار چالش برانگیز است این است که در رایانش بدون سرور اپهای ما کانتینرایز می شوند و چون محیط کانتیر محیطی ایزوله است، امکان مطالعه و دیباگینگ ممکن نیست. بعلاوه توابع تنها در حالت استفاده در پلتفرم زنده هستند؛ پس مدت زمان اشکالزدایی ما نیز بسیار محدود می شود. باید به این نکته دقت داشت که به طور متوسط در رایانش بدون سرور، توابع ۹۹درصد زمان را از تاریخ استقرار روی سرور، درخواب هستند. اما در مورد پایش نرمافزار پلتفرم بدون سرور در داشبورد مدیریتی خود امکاناتی جهت مشاهده منابع مصرف شده، منابع آزاد مدت زمان استفادهشده، تعداد درخواستها و فراخوانی ها، تعداد شروعهای سرد و ... دارد. به علاوه ابزارهای پایش مانند prometheus با این سرورها پلتفرمها امکان اتصال دارند و با پنلهایی مانند grafana می توان از مانیتورینگ مضاعف برای این سرورها بهره برد.

۴.۱.۲ پلتفرمهای تجاری

پلتفرمهای اندکی برای این قسمت وجود دارد. معروفترین آنها عبارتند از: AWS Lambda Funcitons ، AWS Lambda Funcitons

IBM OpenWhisk و Microsoft Azure Functions

AWS Lambda Functions .1

پلتفرم AWS [۶] پلتفرم ارائه شده در بحث رایانش بدون سرور بود که دارای خلاقیتهای بسیاری بود. از مدل برنامهنویسی، مدل هزینهای، محدودیت منابع، امنیت و مانیتورینگ مخصوص خود استفاده می کند. همچنین AWS از زبانهای Python ،Node.js ،Java و سی شارپ پشتیبانی می کند. این پلتفرم ارتباط خوبی با سایر خدمات و سرویسهای AWS دارد و در این اکوسیستم اصطلاحا حل شده است.

Functions Cloud Google .Y

پلتفرم شرکت گوگل با نام Google Cloud Functions [۷] به تازگی از حالت آلفا خارج شده. این سرویس از زبانهای بسیاری ساپورت نمی کند ولی به خوبی به درخواستهای HTTP و HTTPS پاسخ می دهد. در حال حاضر اگرچه عملکرد محدودی برای این پلتفرم شاهد هستیم ولی با توجه به سابقه گوگل و معماری

متفاوت این پلتفرم، آینده خوبی برای آن میتوان متصور بود. این پلتفرم هنوز به خوبی با سرویسهای رایانش ابری گوگل ارتباط برقرار نکرده و جای کار بیشتری دارد.

Functions Azure Microsoft . "

پلتفرم بعدی، پلتفرم وبهوکهای Microsoft Azure Functions این پلتفرم وبهوکهای HTTP را برای این پلتفرم بعدی، پلتفرم وبهوکهای Microsoft Azure Functions بعدی، پلتفرم بعدی، پلتفرم سازی کرده است. از زبانهای Bash همهای این بروژه سازی کرده است. از زبانهای داکری استفاده می کند) پشتیبانی می کند. بخشی از کدها و پروژههای انجام شده با این پلتفرم توسط مایکروسافت در گیتهاب این پروژه متنباز شده اند. همچنین برای راحتی دیباگنگ مایکروسافت در Laching مربوطه امکان Caching یا استفاده از حافظه موقت را گنجانده است. این پلتفرم به مقبولیت قابل قبولی در بین جوامع توسعهدهندگان رسیده و روز به روز بر امکانات آن افزوده می گردد.

OpenWhisk Apache . §

پلتفرم آخر، پلتفرم OpenWhisk [۹]است که در برابر پلتفرمهای دیگر البته بسیار ساده تر به نظر می رسد. این پلتفرم اپن سورس توسط شرکت IBM تولید و پشتیبانی می شود. از قابلیت استفاده زنجیره ای توابع بهره می برد و در مبحث Orchestration توابع از پلتفرمهای رقیب خود جلوتر است (منبع به مقاله ۱). همچنین OpenWhisk توانایی اجرای هر تابعی را دارد؛ زیرا از داکر به عنوان runtime نیز استفاده می کند. سورس این پروژه در آدرس گیتهاب OpenWhisk موجود است. در شکل زیر نیز می توان معماری آن را مشاهده کرد.

همانگونه که در شکل بالا مشخص است. این معماری خیلی به معماری مینیمال یک پلتفرم بدون سرور شبیه است. البته در مقایسه با شکل قبل امکانات بیشتری از جمله امنیت، مانیتوریگ و لاگگیری را اضافه کرده است.

۵.۱.۲ پلتفرمهای آزاد و متن باز

علاوه بر موارد فوق پلتفرمهای متن بازی برای رایانش بدون سرور ارائه شده که در ادامه شرح خواهیم داد.

۱. يتلفرم Open Whisk

اگرچه این پلتفرم در قسمت قبل معرفی شد، اما به صورت متن باز وجود دارد و تنها IBM با پیاده سازی و ادغام در پلتفرم که پلتفرم را به سادگی IBM است، کسب درآمد می کند. این پلتفرم را به سادگی می توان بر روی ماشینهای مجازی یا دستگاههای شخصی پیاده سازی کرد.

Y. يلتفرم Openfaas

پلتفرم بعدی، پلتفرم openfaas است که توسط جوامع ازاد توسعه داده شده است. پشتیبانی از زبانهای جاوا، سیشارپ، پایتون و ... از ویژگیهای آن است. برای کانتیرسازی نیز از داکر به عنوان cli و موتور کانتینر سازی استفاده می کند. همچنین registery پیش فرض در این ابزار داکر ریجستری است. جامعهی رو به رشدی دارد و برای بسیاری از پروژههای کوچک و شرکتهای متوسط مناسب است.

۳. پلتفرم Open Lambda

این پلتفرم از پلتفرمهای جدید و متن باز است که تلاش می کند بسیاری از چالشها و مسائل باز این حوزه را به طور خلاقانهای حل کند. از ویژگیهای پلتفرم open lambda میتوان به زمان اجرای سریعتر تابع ها به خاطر زمان شروه بهتری نسبت به سایر نمونه ها نام برد. همچنین از توابع state-ful هم پشتیبانی می کند. همچنین استفاده از توابع بدون سرور با دیتابیسها و دیباگینگ بهتر فراهم شده است. [۱۰]

Function-as-a-Service 7.7

واژه ی بعدی که در این حوزه بسیار مطرح می شود واژه ی Function-as-a-Servcie یا به اختصار FaaS است. FaaS یک دسته بندی جدید در سرویسهای رایانشی است که با استفاده از یک پلتفرم بدون سرور، به اجرا، توسعه یا مدیریت توابع، بدون هیچگونه پیچیدگی خاص یا نگرانی برای نگه داری زیرساخت که برای استقرار و پیاده سازی یک اپلیکیشن که سابقا و در مدلهای غیر بدون سرور، باید کانفیگ می کرده ایم.

تولید یک نرم افزار بر اساس FaaS، روشی برای رسیدن به یک مدل رایانشی بدون سرور است و در قالب

توسعهی میکروسرویسها و نانوسرویسهایی در توابع، بهدست می آید. از آنجایی که FaaS به صورت حین تقاضا ۱ به ما خدمات می دهد برای توسعه ی خدماتی که به تجزیه و تحلیل داده نیاز دارند مانند سرویسهای اینترنت اشیا، برنامههای موبایل و وب اپلیکیشها بسیار کاربرد دارد.

حال می توان به مقایسه بین رایانش بدون سرور با FaaS پرداخت، بر اساس تعریف FaaS را می توان یک پیاده سازی از رایانش بدون سرور نامید. همچنین رایانش بدون سرور منتهی به اجرای توابع تحت سرویس نمی شود. بلکه حوزه های وسیع تری از جمله Mobile-Backend-as-a-Service یا درمواردی PaaS را شامل می شود.

Scale-to-Zero 7.7

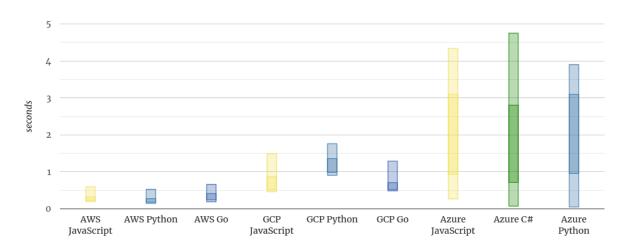
یکی از ویژگیهای کلیدی در رایانش بدون سرور، قابلیت Scale-to-Zero است. این قابلیت موجب پیادهسازی پلنهای هزینه مانند پلن هزینه ردخت حین مصرف میشود. قابلیت scale-to-zero یعنی اینکه در پلتفرم ما هرگاهی که تابع مدت زیادی بلا استفاده باشد، منابع پردازشی آن گرفته میشوند و آن تابع اصطلاحا علادا میشود تا تابع دیگر فعال نباشد. اگر از دید ارائه دهنده خدمات به این موضوع نگاه کنیم، برای ما این فایده را دارد که منبع بلااستفاده ما در این حالت آزاد میشود و آن منبع (RAM و CPU) به کانتینر دیگری که میخواهد استفاده شود اختصاص می یابد. طبق آمار توابع در FaaS به ندرت صدا زده میشوند. ۸ طبقه بندی برای فراخوانی توابع انجام شده و مشخص شده که ۱۰۵٪ توابع زیر ۱ ثانیه و ۱۹۶۰ آنها زیر ۹ ثانیه اجرا میشوند [۴]. بنابراین اگر منبع به یک تابع به مدت زیادی اختصاص یافته باشد دچار اتلاف منابع زیادی خواهیم شد.

از دید کاربر هم اگر بخواهیم به موضوع نگاه کنیم. Scale-to-Zero باعث فراهم شدن ویژگی پرداخت حین استفاده می شود. این صرفه اقتصادی بزرگی برای ما دارد. فرض کنید یک اپلیکیشن در حال اجرا داریم که اجرای انفجاری دارد و این اپلیکیشن به ندرت اجرا می شود. اگر بخواهیم از مدلّهای قدیمی پرداخت استفاده کنیم، باید هزینه زیادی صرف کنیم، در حالی که در اکثر اوقات تابع ما هم بلا استفاده است. در حالی که با مدل پرداخت در سیستمهای بدون سرور، این مورد بسیار برای ما به صرفه می شود.

دو مورد بالا از مزایای قابلیت Scale-to-Zero در سیستمهای بدونسرور هستند. اما در اینصورت با یک

¹on-demand

²pay-as-you-go



شکل ۳.۲: اهمیت زبان و پلتفرم بدون سرور در تاخیر شروع سرد

چالش جدی به نام تاخیر شروع سرد هم مواجه خواهیم شد که در ادامه به آن می پردازیم.

۴.۲ تاخیر شروع سرد

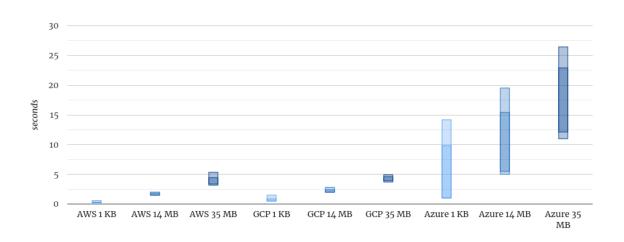
درقسمت قبل به بیان ویژگی Scale-to-Zero در پلتفرمهای بدون سرور و مزایای آن پرداختیم. اما این ویژگی معایبی هم دارد. یکی از مهمترین معایب آن، تاخیر شروع سرد است.

بگذارید تاخیر شروع سرد را در قالب یک مثال بیان کنیم. فرض کنید پس از مدتی بلا استفاده بودن تابع منابع آن گرفته شده و اصطلاحا سرد شده است. حال یک درخواست برای اجرا برای آن تابع سرد شده میرسد. درحالی که تابع ما منبعی ندارد و اجرا نمی شود؛ آن درخواست باید مدتی منتظر بماند تا تابع مورد نظر ما دوباره آماده شود و در سرور بارگذاری شود. این آماده سازی، مراحل مختلفی دارد که در تصویر ۳.۲ نشان داده شده است.

همانگونه که در تصویر ۳.۲ میبینیم، این آماده سازی شامل آماده سازی کانتینرها، آماده سازی تابع، اختصاص منابع به کانتینر و در نهایت، اجرا در پلتفرم است. این تاخیر بسیار قابل توجه است و در شکل ۱.۱ نیز به خوبی نشان داده شده است.

همچنین، یکی از مواردی که شروع سرد اتفاق میافتد، فراخوانی تابع برای اولین بار در پلتفرم است.

¹Cold Start Latency



شکل ۴.۲: اهمیت اندازه کتابخانه برنامه در تاخیر شروع سرد

حال چه عواملی در شروع سرد نقش دارند؟ عوامل عمده ای در این کار دخیل هستند ولی مهمترین آنها زبان برنامهنویسی و نوع پلتفرمی که در آن کد را اجرا می کنیم و کانفیگ نرمافزاری و سختافزاری آن پلتفرم است.

در مورد اهمیت زبانهای برنامه نویسی میتوان گفت چون زبانهای مختلف زمان اجراهای متفاوتی دارند بنابراین موثر هستد. شکل زیر اهمیت زبانهای برنامهنویسی را نشان میدهد. در این شکل از پلتفرمهای مختلف برای اجرای توابع مختلف برای محاسبهی زمان اجرا با درنظر گرفتن تاخیر شروع سرد استفاده شده است.

در آزمایش دیگری با جاوا اسکریپت تابعهای یکسانی نوشته شده با این تفاوت که حجم کتابخانههای هر تابع متفاوت است. این آزمایش در پلتفرمهای مختلف نیز انجام شده و نتیجه طبق شکل زیر رسم شده است.

بنابراین با توجه به شکل ۴.۲ می توان نتیجه گرفت حجم کتابخانه توابع نیز در مدت زمان تاخیر شروع سرد بسیار موثر است.

فصل ۳

کارهای مرتبط

قبل از بررسی درخت موضوعی بهتر است به مبحث ترکیب توابع در پلتفرمهای بدون سرور بپردازیم. در [۱۱] ۷ ترکیب از توابع در FaaS بررسی شده است. البته این مقاله ذکر می کند که ۲ دستهبندی اصلی در رایانش بدون سرور داریم: FaaS بررسی شده است. از توابع عنوان سرویسهای سمت سرور برنامههای کاربردی وب و موبایل بدون سرور داریم: FaaS و FaaS یک نمونه از آن است. در حال حاضر این دستهاز سرویسهای ابری به شدت در حال توسعه است و البته، تمرکز این مقاله بر روی این موضوع هم نخواهد بود.

یکی از چالشهای اصلی معماری بدون سرور در ان است که برای تولید یک برنامه کاربردی بزرگ یا تجاری، باید جریانهای کاری پیچیده ای را ایجاد کنیم. برای همین کار باید تعداد زیادی تابع را ایجاد کنیم که این توابع باید به اشکال مختلف هم دیگر را فراخوانی کنند. مثلا بعضا ممکن است یک تابع بعدی را فراخوانی کند یا یک تابع لازم باشد همزمان چند تابع را فراخوانی و اجرا کند و پیاده سازی یک راه حل درست برای این مورد بسیار برای رسیدن به معماری میکروسرویس برای ما مهم و حیاتی است و هرگونه کوتاهی و خطا در راه حل، باعث کارایی یایین محصول نهایی خواهد شد و با مشکلات بسیاری در پیاده سازی، ما را مواجه می سازد.

برای حل این معضل، ارائه دهندگان خدمات تجاری اقدام به معرفی سرویسهایی تحت عنوان FaaS Orchestrator برای حل این معضل، ارائه دهندگان خدمات تجاری اقدام به معرفی سرویسها ایجاد و پشتیبانی از ترکیبتوابع و سناریوهای پرکاربرد برای دستیابی به عملکرد موروان در برنامههای کاربردی تحت پلتفرم بدون سرور است. دو پلتفرم معروف Orchestrator عبارتند از: AWS روان در برنامههای کاربردی تحت پلتفرم بدون سرور است. دو پلتفرم معروف Step Functions (با به اختصار ASF) و دیگری Step Functions

توابع ترکیب شده توسط Orchestratorها حتما باید ۳ معیار را ارضا کنند:

- ۱. ترکیبات توابع باید به گونهای باشند که جعبه سیاه بودن توابع نقض نشوند. یعنی فقط باید بتوانیم از روی ورودی و خروجی توابع محتوای آن را حدس زد.
 - ۲. این ترکیبها تابع قوانین و قواعد مشخصی باشند. همچنین، این ترکیبات باید قابل جایگزینی باشند.
 - ۳. نباید بگونهای فراخوانی اتفاق بیافتد که برای محاسبه ی هزینه همزمان یول ۲ تابع یا بیشتر را بدهیم ۱.

ما از این سه قانون با عنوان لمهای بدون سرور ۲ یاد می کنیم و هر ترکیبی از توابع که این ۳ معیار بالا را ارضا

¹double billing

²Serverless Trilemma

Wrapper

...code... \[\lambda1() \]
\[\lambda2() \]
\[\lambda3() \]
...code...

```
import boto3, json
def lambda_handler(event, context):
    invokeLam = boto3.client("lambda", region_name="us-east-2")
    payload = {"message": "Test"}
    resp = invokeLam.invoke(FunctionName="Lambda1", InvocationType = "Event",
Payload = json.dumps(payload))
    print("Lambda1 Invoked ")
    resp = invokeLam.invoke(FunctionName=" Lambda2", InvocationType =
"Event", Payload = json.dumps(payload))
    print("Lambda2 Invoked ")
    resp = invokeLam.invoke(FunctionName=" Lambda3", InvocationType =
"Event", Payload = json.dumps(payload))
    print("Lambda3 Invoked ")
    return {
        'statusCode': 200,
        'body': json.dumps('Hello from Lambda!')
}
```

شکل ۱.۳: الگوی بازتابی در فراخوانیها

کند، ST-Safe نامیده می شود. ترکیبات معروف توابع به شرح زیر است:

- ۱. ترکیب با استفاده از بازتاب^۱: به این صورت است که یک تابع اقدام فراخوانی سایر توابع به صورت همزمان ^۲ می کند. در شکل ۱.۳ یک نمونه مثال از فراخوانی همزمان توابع ذکر شده است. تنها مشکلی که دارد این است که با معضل Double billing مواجه خواهیم شد.
- ۲. ترکیب همجوشی^۳: در این حالت تابع wrapper، توابعی که فراخوانی کرده ایم در تابع اصلی را بارگذاری میکند. مشکل اصلی آن این است که اصل جعبه سیاه را نقض میکند و همچنین باید توابع حتما با یک زبان نوشته شوند. شکل ۲.۳ یک الگوی همجوشی را نشان میدهد.
- ۳. ترکیب غیرهمزمان: در این حالت، تابع اول به فراخوانی تابع دوم میپردازد درحالی که اولی دیگر فعال
 نیست. این ترکیب نیز قانون دوم ST را نقض می کند.
- ۴. ترکیب توسط مشتری: در این حالت توابع ساخته می شود و خود مشتری خارج از سیستم بدون سرور اقدام
 به ترکیب توابع می کند. معروف ترین نمونه آن ASF است و اصل اول را نقض می کند.
- ۵. ترکیب زنجیرهوار: در این ترکیب، یک ترکیب پس از اتمام اقدام به فراخوانی تابع بعدی می کند و همینطور ادامه پیدا می کند. این ترکیب مشکل double billing دارد و ST-Safe نیست. در شکل ۳.۳ الگوی زنجیرهای نمایش داده شده است.

¹Reflection

²synchronous

³Fusion

Wrapper

```
...code...

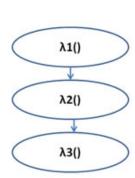
def func1()
{
}
def func2()
{
}
def func3()
{
}
func1 ()
func2()
func3()
...code...
```

```
import json
def lambda_handler(event, context):

    def func1(param):
        print("1 Exit")
    def func2(param):
        print("2 Exit")
    def func3(param):
        print("3 Exit")

    param="Test Payload"
    func1(param)
    func2(param)
    func3(param)
    return {
        'statusCode': 200,
        'body': json.dumps('Success!')
}
```

شکل ۲.۳: الگوی همجوشی در فراخوانیها



```
Lambda1
def lambda handler (event, context):
    invokeLam = boto3.client("lambda", region name="us-east-2")
    payload = { "message": "Test"}
    resp = invokeLam.invoke(FunctionName="Lambda2",
InvocationType = "Event", Payload = json.dumps(payload))
   print ("Lambdal Exit")
    return {
        'statusCode': 200,
        'body': json.dumps('Success 1')
    }
Lambda2
import boto3, json
def lambda handler(event, context):
    invokeLam = boto3.client("lambda", region_name="us-east-2")
    payload = {"message": "Test"}
    resp = invokeLam.invoke(FunctionName="Lambda2",
InvocationType = "Event", Payload = json.dumps(payload))
    print("Lambda2 Exit")
    return {
        'statusCode': 200,
        'body': json.dumps('Success 2')
Lambda3
import json
def lambda handler (event, context):
   print ("Lambda3 Exit")
    return {
        'statusCode': 200,
        'body': json.dumps('Success 3')
```

شکل ۳.۳: الگوی همجوشی در فراخوانیها

ای ترکیب توابع	ی بین روش ہ	۱.۱: مقایسه	جدول "
	O 77 O 88 O	••	U

مدت زمان اجرای برنامه تست	کدام محدودیت ST نقض می شود؟	poly glot پشتیبانی از	نوع ترکیب
311.0.	پرداخت مجدد ^۱	بله	بازتاب
2.47	جعبهسیاه ^۲	خير	همجوشى
نامشخص	نامشخص	نامشخص	غیرهمزمانی"
331.83	قاعده تركيب توابع	بله	ترکیب توسط مشتری ^۴
1104.78	پرداخت مجدد	بله	زنجیرهای

مقایسهی این ترکیبات در جدول ۱.۳ به طور خلاصه بیان شده است:

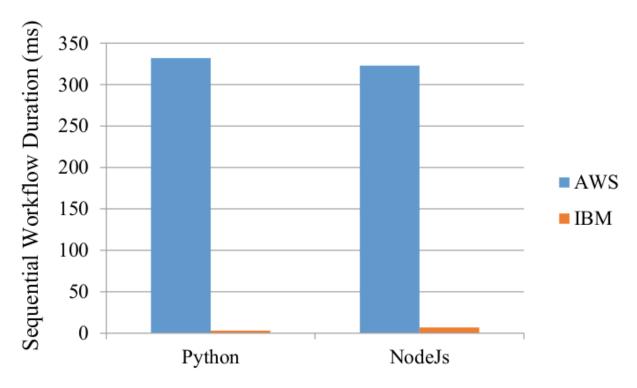
در نهایت با مقایسه دو پلتفرم ASF و IBM Cloud Function Sequences برای یک برنامه تست مشابه به مدتزمان های اجرای شکل ؟؟ میرسیم.

۱.۳ درخت موضوعی

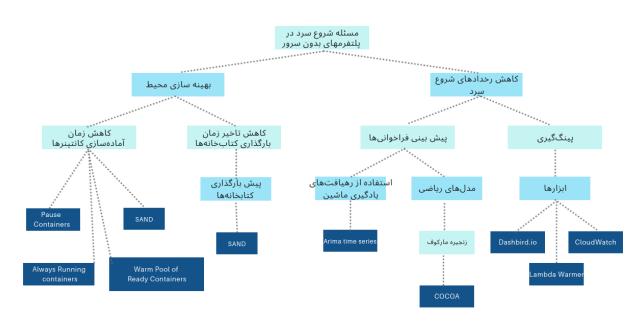
در این قسمت به بیان کارهای انجام شده در این حوزه خواهیم پرداخت و برای این کار درخت موضوعی مرتبط با آن رسم شده. هر گره ار درخت موضوعی یک راهکار برای جلوگیری از رخداد شروع سرد است و هر گره دارای بخشهایی است تا به برگ برسیم. در شکل ۵.۳ درخت موضوعی نمایش داده شده است و هر گره را به ترتیب بررسی خواهیم کرد.

ریشه درخت مسئله شروع سرد است که ۲ گره اصلی دارد. گره سمت چپ که بهینه سازی محیط نام دارد، تلاش می کند تا در صورت وجود رخداد شروع سرد زمان آنرا به حداقل برساند. این گره ۲ فرزند دارد که عبارتند از کاهش تاخیر آماده سازی کانتینرها و کاهش زمان بارگذاری کتابخانهها. یک روش برای کاهش زمان بارگذاری کتابخانه ها استفاده از روش پیش-بارگذاری است.

گره سمت راست ریشه هم کاهش رخدادهای شروع سرد است. تمرکز این گره در این است نگذاریم شروع سرد



شکل ۴.۳: مقایسه زمان اجرا ۲ برنامه مشابه با Node.js و پایتون در دو پلتفرم ASF و Node.js و PNode.js



شکل ۵.۳: درخت موضوعی

رخ دهد. گره سمت راست این نود، روش پینگ گیری است؛ در این روش سعی می کنیم با استفاده از ابزارهایی جلوگیری کنیم از سرد شدن توابع. در آخرین سطح این گره هم ابزارهای مرتبط معرفی شده اند. فرزند سمت چپ گره کاهش رخداد، پیشبینی فراخوانیها است. در پیشبینی فراخوانی ها می توان از رهیافتهای بدست آمده در یادگیری ماشین بهره جست. روش دیگر استفاده از مدلهای ریاضیاتی غیریادگیری ماشین برای پیشبینی فراخوانیها است. یکی از این روشهای استفاده از ماشینهای حالت محدود بدست آمده با روش زنجیره مارکوف است.

در برگهای این درخت هرکدام یک مقاله را بررسی می کنیم. در ابتدا به توضیح درباره روشهای بهینهسازی محیط می پردازیم و سپس به سراغ کاهش رخداد میرویم. در هر حوزه یک مقاله نمونه بررسی خواهد شد.

۲.۳ بهینه سازی محیط

در این روش قرار به این است که مانع وقوع شروع سرد نشویم (در واقع هم نمی توان مانع از اتفاق شروع سرد شد)؛ بنابران به دنبال روش یا روشهایی برای کاهش زمان شروع سرد هستیم. همانگونه که بالاتر ذکر کردیم، این موضوع را می توان از دو جنبه بررسی کرد. اول اینکه آماده سازی کانتینرها را کاهش دهیم. روش دیگر این است که زمان لودشدن کتابخانه ها برای اجرای تابع را کاهش دهیم. برای این کار می شود از روش پیش-بارگذاری کتابخانه ها استفاده کرد.

1.۲.۳ کاهش زمان آمادهسازی کانتینرها

در این روش دنبال کمینهسازی زمان شروع سرد با استفاده از روشهایی برای کانفیگ بهینه محیط برای مواجهه با شروع سرد هستیم. عمده کارهایی که در این بخش انجام میدهیم در سطح شبکه یا کانتینرها برای بهینه سازی است که روشهای نسبتا سطح پایینی محسوب میشوند.

یکی از مواردی که شروع سرد به شدت رخ می دهد، زمانی است که بنابه دلایلی تابع در خواستهای زیادی دارد. این موضوع در [۲] ذکر شده است. نویسنده معتقد با انجام این بهبودها در حدود ۸۵٪ مدت زمان شروع سرد برای این توابع صرفه جویی خواهد شد. این مقاله از پلتفرم Knative برای پیاده سازی تغییرات استفاده می کند.

علت انتخاب Knative این است که بر روی بستر کوبرنتیز ساخته می شود و از مفاهیمی مثل Pod ها برای اجرای توابع و جریانهای کاری استفاده می کند. بنابراین، از آنجایی که کوبرنتیز دست ما را برای انجام تغییرات باز می گذارد، می توان به آسانی به پیاده سازی سیاستهای خودمان بپردازیم. در پلتفرم Knative هر تابع در درون یک پاد اجرا می شود. پادها، ابتدایی ترین و ساده ترین بارهای کاری (به هر برنامه در حال اجرا در کوبرنتیز بارهای کاری می گوییم. توجه داشته باشید در کوبرنتیز بارکاری یک موجودیت نیست در واقع مفهومی است که به اجرای کانتینرها و تخصیص CPU و ... اشاره دارد.) در کوبرنتیز هستند. در درون هر پاد تعدادی کانتینر اجرا می شود. در یک پاد شبکهها، ذخیره سازی (Storage) به صورت مشترک است. البته باز هم به خاطر وجود بحثهایی مثل Cgroups و anamespace که ساختمان داده اصلی کانتینرها هستند، کانتینرهای داخل یک پاد از هم ایزوله هستند. پادهادر کوبرنتیز موجودیتهای موقتی هستند و درصورت از دست رفتن نود، اتمام کار، کمبود منابع سرور و دلایل دیگر می توانند از سرور خارج شوند و دیگر قابل بازیابی نیستند.

نکتهای که باید توجه داشت این است که یک پاد از جنس یک پردازه ۲ نیست؛ بلکه، محیطی منطقی برای اجرای کانتینرهاست و این کانتینرها هستند که از جنس پردازه ها هستند. داده های درون کانتینرها وابسته به پادها هستند و با ری استارت شدن پادها محتویات ذخیره شده در کانتینرها از بین می روند مگر اینکه در ذخیره سازها ذخیره شوند. [۱۲]

با توجه به مقدماتی که در مورد پادها ذکر شد، اکنون منطقی به نظر میرسد برای مدیریت کانتینرها بخواهیم از یادها استفاده کنیم و این رهیافت دست ما را برای اعمال تغییرات مختلف روی یلتفرم باز می کند.

ما به صورت ایده آل دنبال کمترین سربار برای فراخوانی توابع هستیم. هنگامی که برای اولین بار تابع را فراخوانی می کنیم دچار تاخیر شروع سرد می شویم که در بخش ادبیات موضوع (رفرنس به شروع سرد) در مورد آن مفصلا بحث کردیم. این مشکل در تمامی پلتفرمهای بدون سرور، مشکل رایجی است. سربار شروع سرد را می توان به ۲ قسمت تعیین کرد:

۱. سربار ناشی از اجرای یلتفرم

علت اصلی این سربار اجرای پلتفرم است و به علت قرار گرفتن در صف یا دلایل دیگر باعث تاخیر میشود.

¹policy

²Process

از این دسته خطاها می توان به provisioning pod bootstraping، network یا sidecar nework اشاره کرد.

۲. سربار ناشی از خود اپلیکیشن

علت اصلی این سربار مشکلات خود برنامه است. این نوع تاخیر به مواردی از جمله زبان برنامهنویسی، حجم برنامه و نوع کتابخانههایی که از آنها استفاده می کنیم بستگی دارد.

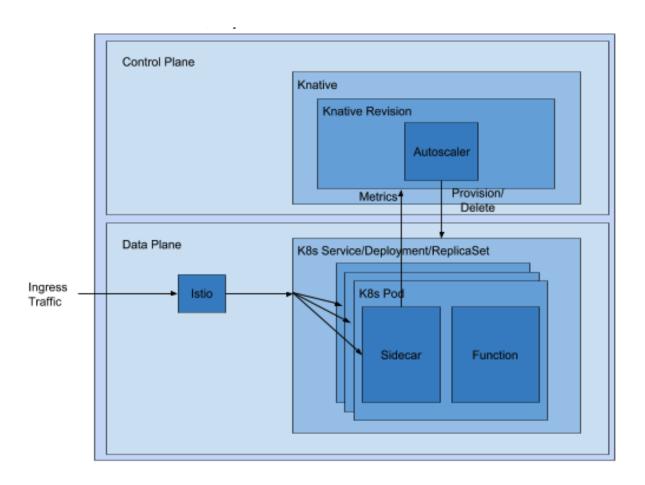
برای مثال اجرای یک HTTP Server ساده شروع سردی در حدود ۵ ثانیه را به خود اختصاص می دهد؛ در حالی که با اجرای یک برنامه کلاس بندی عکس زمان شروع سرد به چیزی در حدود ۴۰ ثانیه هم برسد.

بنابراین، ایده این مقاله این است که برای اجرای توابعی که اخیرا محبوب شده اند از رهیافت استفاده از یک استخر گرم برای نگه داری این پاد استفاده کنیم. دقت کنید که در اینجا، در داخل هر پاد تنها یک کانتینر که آن کانتینر هم برای یک تابع است، اجرا می شود. هرگاه که در خواست جدید برای تابع می رسد در ابتدا استخر گرم را چک می کنیم که آیا پاد در آن موجود است یا خیر؟ اگر پاد در آن وجود داشت دیگر منتظر نمی مانیم، سریع تابع را در پلتفرم اجرا کرده و دیگر تاخیر شروع سرد را نخواهیم داشت. بنا به محاسبه نویسنده مقاله، این روش تا ۸۵٪ زمان شروع سرد را برای توابع on-demand نسبت به حالت عادی، کاهش می دهد.

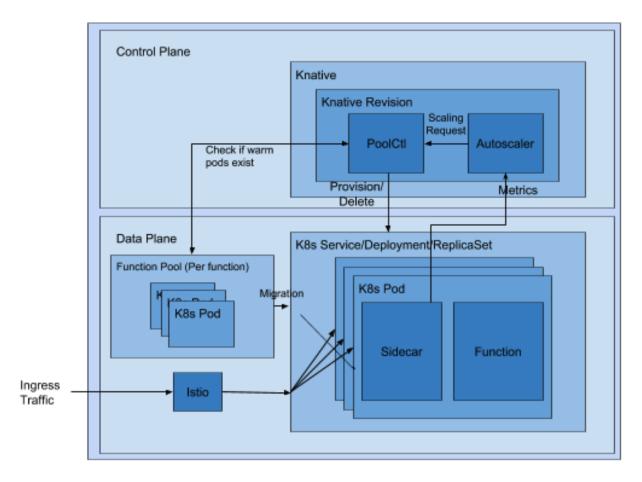
اما چگونه این تغییرات انجام شده است؟ شکل ؟؟ نمایشگر معماری پلتفرم بدون سرور Knative است. انتظار داریم با بهینه سازی هایی این رهیافت را برای مدیریت شروعهای سرد اعمال کنیم.

همانگونه که در این شکل می بینیم، وظیفه مولفه autoscaler، انجام وظایف مربوط به Scale up/down است. همانگونه که در این شکل می بینیم، وظیفه مولفه autoscaler دستور به ساخت پاد را می دهد ولی از آنجایی که این هنگامی که دچار شروع سرد می شویم، مولفه autoscaler دستور به ساخت پاد را می دهد ولی از آنجایی که این امر وقت گیر است انجام آن بسیار طول می کشد. نهایتا اینکه پس از مدت زیادی پاد ساخته شده و داخل بخش امر وقت گیر است انجام آن بسیار طول می کشد. نهایتا اینکه پس از مدت زیادی پاد ساخته شده و داخل بخش امر وقت گیر است انجام آن بسیار طول می کشد.

برای حل این مشکل، مقاله پیشنهاد می دهد تا در بخش control plane و داخل revision پلتفرم به ساخت مولفه مدیریت استخر قرار دهیم که آن با توجه به در خواستهایی که برای auto-scaler می رسد، اقدام به ساخت پادهایی و نگهداری آن در استخر گرم که در بخش data plane توسعه داده شده، می کند. استخر گرم محدودیت هایی مثل اندازه استخر دارد و تنها تعداد محدودی پاد در آن می توان نگه داشت. حال اگر در خواستی برای پلتفرم



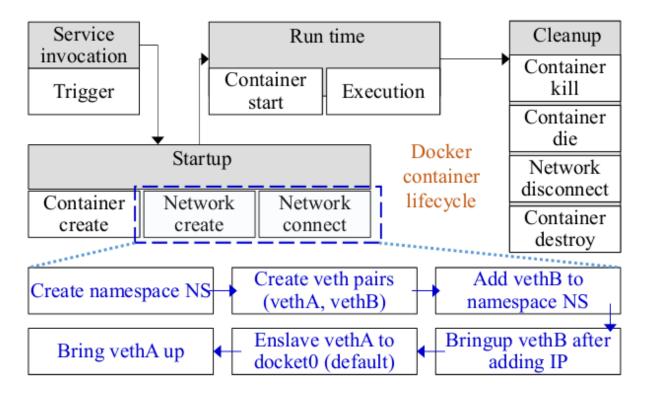
شكل ۶.۳: معماري پلتفرم Knative



شکل ۷.۳: معماری پیشنهادی مقاله برای حل تاخیر شروع سرد

برسد، autoscaler ابتدا از کنترل کننده استخر وضعیت موجودی در استخر گرم را بررسی می کند. اگر در استخر پاد موجود باشد در اینصورت بلافاصله مهاجرت (migration) از استخر گرم به سرویس رخ می دهد. از آنجایی که در استخر گرم منابع به پاد اختصاص داده شده و پاد کاملا آماده ی اجرا است؛ بنابراین، تاخیر شروع سرد بسیار ناچیزی خواهیم داشت. اما از طرفی، اگر پاد در استخر گرم موجود نباشد، دچار تاخیر شروع سرد خواهیم شد. نکته ی منفی این روش این است که در صورت رخداد شروع سرد، به میزان تاخیرهای قبل، تاخیر ناشی از استعلام از استخر گرم هم اضافه خواهد شد. شکل ۷.۳ مدل جدید مقاله برای مدیریت شروع سرد را نشان می دهد. [۱۲] مقاله دیگری که در این حوزه اقدام به بررسی تاثیر آماده سازی کانتیرها پرداخته از ایده container pause ها که مفهومی در کوبرنتیز است استفاده می کند. ؟؟ این مقاله اقدام به بررسی تاخیر شروع سرد ناشی از اجرای همزمان تعدادی تابع کرد و نتایج خروجی آن را در شکل ۱.۱ نشان داده اند.

¹pool controller



شکل ۸.۳: مراحل ساخت یک فضای نام در داکر

در این واقع، این مقاله تاخیر شروع سرد را ناشی از آماده سازی کانتینرها میبیند و سعی می کند تا حد امکان با آن مقابله کند. برای نمایش و پیاده سازی سناریو خود از پلتفرم Apache OpenWhisk استفاده کرده اند. طبق همان شکل نتیجه می گیریم که بخش عمده ای از تاخیرها ناشی از تاخیر در آماده سازی کانتینرها است، زیرا باید گامهای طولانی برای ساخت و استقرار یک کانتینر و اختصاص شبکه به آن برداریم. شکل ۸.۳ این گام ها را نشان می دهد.

همانگونه که در شکل مشخص است برای اجرای یک تابع در پلتفرم، ابتدا باید کانتیر آن ساخته شود. بسیاری از پلتفرمها از جمله پلتفرم بدون سرور انجام می دهد، - ازموتور داکر به عنوان موتنو کانتینری در پلتفرم خود پشتیبانی می کنند. در این موتور مراحل شکل فوق باید انجام بشود تا یک کانتینر کاملا آماده شود.

با توجه به شکل، تمامی بهبودهایی که باید انجام دهیم در مرحله شروع اولیه کانتینر است، جایی که دقیقا ۳ مرحله داریم. ساخت کانتینرها، ساخت شبکهها و اتصال کانتینرها به آنها و در نهایت اتصال شبکهها.

در مرحلهای اول باید فضای نامرا برای هر شبکه ایجاد کنیم. این کار در داکر توسط یک ویژگی کرنل لینوکس

به نام فضای نام ۱ انجام می گیرد. فضای نام یه مانع یا ایزوله کننده شبکه است که فرایند مختلف را از یکدیگر جدا می کند. در هر فضای نام پس از ایزوله سازی می توان مطمئن بود که دسترسی به پردازه های دیگر به شدت محدود شده است. اما، ما به دنبال ایزوله کردن پروسه نیستیم، بلکه به دنبال این هستیم که اجرا پردازه در سیستم عامل ایزوله باشد ولی ارتباط با آن نیز ممکن باشد. بنابراین باید تنظیمات شبکه در آن را انجام دهیم.

بنابراین به دنبال ایجاد جفتهای veth هستیم. جفتهای veth یک سری کابل مجازی هستند (به طور دقیق از جنس خط لولهها در سیستم عامل هستند) که وظیفه انتقال یک طرفه از کانتینر به فضای بیرون از آن و بالعکس را دارا میباشند. پس اقدام به اضافه کردن eveth به شبکه می کنیم. این دوقسمتی که مطرح شد خود شامل ۶ مرحله کلی می شود که توضیح آن در این گزارش جایی ندارد.

حال نقش شبکهها در شروع سرد چیست؟ همانگونه که قبلا گفتیم، هر کانتینر از ۴ مرحله می گذرد. مرحله اول، مرحله فراخوانی سرویس هاست که در آن یک درخواست ساخت کانتینر برای اتصال به محیط پیرامون می شود. مرحله دوم مرحله آغازکردن تنام دارد که در طی آن یک کانتینر باید برای اتصال به محیط پیرامون آماده شود بنابراین کانتینر ساخته شده، شبکه درون و بیرون کانتینر کانفیگ می شود و به هم متصل می شوند.. مرحله سوم مرحله اجرا ۴ است که در طی آن، تابع اجرا می شود و در انتها مرحله ی نهایی یا مرحله پاکسازی آن است. [۱۳]

علاوه ساخت کانتینرها، به این توجه کنید که ما به دنبال اجرای همزمان آنها نیز هستیم. این مورد زمان و سربار اجرا را نیز به طرز قابل توجهی بالا میبرد. اگر به شکل ۱.۱ نگاه کنید مجددا میبینید که به ازای اجراهای همزمان، زمان آماده سازی بسیار طولانی تر شده است در حالی که، زمان اجرا تغییر چندانی نکرده است.

مقاله می گوید که بر طبق آمارهای گرفته شده، در مرحله آماده سازی کانتینرها، ۴۰٪ زمان آماده سازی مربوط به ۲ مرحله ساخت شبکه ها و اتصال شبکه ها می شود. بنابراین معتقد است که با بهبود در این وضعیت تاخیر شروع سرد تا حد قابل توجهی برای تمامی توابع، کاهش خواهد یافت. حال مشکل اینجااست که این مراحل به کندی انجام می شوند مثلا برای ساخت شبکه این کاریکی یکی و دریک صف به نوبت انجام می شود. با توجه به اینکه در

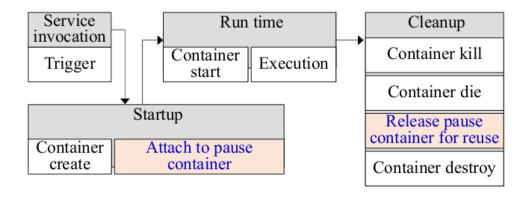
¹namespace

²namespace

³Startup

⁴execution

⁵Cleanup



شکل ۹.۳: استفاده از Pause Containerها برای کاهش تاخیر شروع سرد

پلتفرمهای بزرگ و تجاری در هر لحظه تعداد زیادی کانتینر باید ساخته یا حذف شوند این تاخیر به شدت افزایش پیدا خواهد کرد. برای اینکار آزمایشی انجام شد که نتایج آن در جدول ۲.۳ قابل مشاهده است.

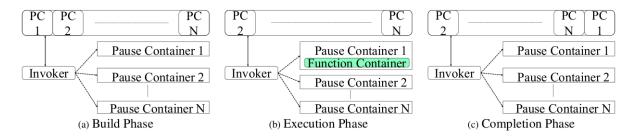
100	50	10	1	تعداد فضاهای نام همزمان
14.41	6.28	1.27	0.28	زمان ساخت
7.77	3.24	0.71	0.20	زمان پاکسازی

جدول ۲.۳: زمان ساخت و پاکسازی کانتیرهای همزمان

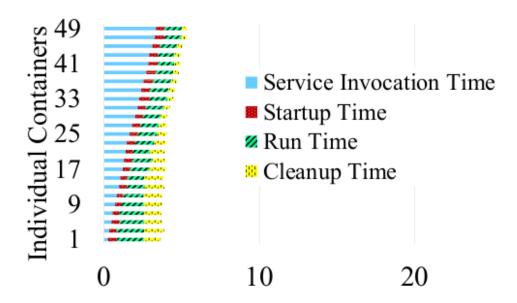
همانگونه که در این جدول قابل مشاهده است، زمان آماده سازی سرویسها به ازای تعداد کانتینرهای همزمان، به طور نمایی افزایش مییابد. در حالی که ما در پلتفرمهای تجاری همزمان تعداد زیادی کانتینر را هم بسازیم یا از بین ببریم.

بهتر است به این دید نگاه کنیم که pause container ها از قبل شبکه را ساخته و کانفیگهای مربوطه را انجام داده اند. پس کانتینری که در درون آن اجرا می شود تنها به معرفی برای اختصاص آدرس IP دارند که کار زمان بری نیست. بنابراین، می توان پس از ساخت یک کانتینر، تنها به اجرای آن در pause container ها بپردازیم و از این طریق در زمان ساخت بسیار صرفه جویی کنیم. همچنین برای پاکسازی تنها باید کانتینر تابع مربوطه را حذف کنیم و pause container بازیابی می شود. این رهیافت در شکل ۹.۳ نشان داده شده است.

در این حالت دو مرحله ساخت و اتصال شبکه جایگزین شده. همچنین برای مدیریت pause container ها نیز یک استخر مربوط به آنها ساخته شده است. در شکل ۱۰.۳ نحوه عملکرد این رهیافت توضیح داده شده است.



شکل ۲۰.۳: مدیر استخر Pause Containerها



شکل ۱۱.۳: نتیاج و بهبود حاصل شده با استفاده از Pause Containerها

در قسمت اول که فاز ساخت است ۷ از قبل تعدادی کانتینر ساخته شده و در یک صف نگهداری می شوند. یک فراخواننده ۱ داریم که وضعیت تمامی ۲PCها را می داند. در قسمت بعدی می خواهیم یک تابع را اجرا کنیم؛ برای اینکار تنها کافی است که آن کانتینر را درون ۲C بارگذاری کنیم. و هرگاه کار تابع تمام شد تنها کافی است آن کانتینر در ۲C را نابود کنیم. در انتها خود ۲C بازیابی می شود و به انتهای صف استخرهای ۲C اضافه می شود. نتایج این رهیافت در شکل زیر نشان داده شده است و می تواند تا ۲۰۸ زمان شروع سرد را برای توابع کاهش دهد. برای مقایسه میزان بهبود داده شده شکل را با شکل مقایسه کنید.

¹invoker

Pause Container مخفف

۳.۳ کاهش رخدادهای شروع سرد

در این قسمت به دنبال روشهایی برای کاهش احتمال شروع سرد در پلتفرمهای بدون سرور هستیم. در واقع ما به دنبال این هستیم که جلوی رخداد شروع سرد را با هایی بگیریم. از دسته بندی های کلی در این مبحث می وان به روشهای جلوگیری از شروع سرد با استفاده از پینگ گیری یا روشهای پیش بینی شروع سرد، اشاره کرد.

۱.۳.۳ پینگگیری

متن تست

استفاده از ابزارها

متن تست

۲.۳.۳ پیشبینی فراخوانیها

متن تست

استفاده از مدلهای ریاضی

متن تست

استفاده از رهیافتهای یادگیری ماشین

متن تست

فصل ۴

نتيجهگيري

نتیجه گیری

در فصل قبل در ارتباط با راهکارهای ارائه شده توسط هر یک از مقالهها به تفصیل، تشریح نمودیم. در این فصل میخواهیم به بیان نتایج و مقایسه راهکارهای ارائه شده بپردازیم. در ابتدا به مقایسههای روشهای مبتنی بر مکانیزم DRX/DTX با یکدیگر میپردازیم.

مراجع

- [1] P. Castro, V. Ishakian, V. Muthusamy, and A. Slominski, "The rise of serverless computing," *Commun. ACM*, vol.62, p.44-54, Nov. 2019.
- [2] P.-M. Lin and A. Glikson, "Mitigating cold starts in serverless platforms: A pool-based approach," arXiv preprint arXiv:1903.12221, 2019.
- [3] A. Mohan, H. Sane, K. Doshi, S. Edupuganti, N. Nayak, and V. Sukhomlinov, "Agile cold starts for scalable serverless," in 11th {USENIX} Workshop on Hot Topics in Cloud Computing(HotCloud 19), 2019.
- [4] M. Shahrad, R. Fonseca, I. Goiri, G. Chaudhry, P. Batum, J. Cooke, E. Laureano, C. Tresness, M. Russinovich, and R. Bianchini, "Serverless in the wild: Characterizing and optimizing the serverless workload at a large cloud provider," in 2020 {USENIX} Annual Technical Conference ({USENIX}{ATC} 20), pp.205-218, 2020.
- [5] I. Baldini, P. Castro, K. Chang, P. Cheng, S. Fink, V. Ishakian, N. Mitchell, V. Muthusamy, R. Rabbah, A. Slominski, *et al.*, "Serverless computing: Current trends and open problems," in *Research Advances in Cloud Computing*, pp.1-20, Springer, 2017.
- [6] A. AWS, "Aws lambda functions," https://aws.amazon.com/lambda/.
- [7] G. INC., "Google cloud fucntions," https://cloud.google.com/functions.
- [8] Microsoft, "Microsoft azure platform," https://azure.microsoft.com/en-us/services/functions/.
- [9] A. openwhisk corporation, "Ibm openwhisk platform," https://openwhisk.apache.org/.
- [10] S. Hendrickson, S. Sturdevant, T. Harter, V. Venkataramani, A. C. Arpaci-Dusseau, and R. H. Arpaci-Dusseau, "Serverless computation with openlambda," in 8th {USENIX} Workshop on Hot Topics in Cloud Computing (HotCloud 16), 2016.

مراجع

[11] U. Bharti, D. Bajaj, A. Goel, and S. Gupta, "Sequential workflow in production serverless faas orchestration platform," in *Proceedings of International Conference on Intelligent Computing, Information and Control Systems*, pp.681-693, Springer, 2021.

- [12] M. Luksa. Kubernetes in Action. 2018.
- [13] S.K. Jeff Nickoloff. Docker In Action. 2019.